[*documento em construção*]

Framework de Avaliação de Prontidão Organizacional para Desenvolvimento de Soluções de IA no Setor Público

1. Introdução

Este framework oferece uma abordagem pragmática, ética e adaptável para avaliar a prontidão de órgãos públicos brasileiros para desenvolver, adotar ou integrar soluções baseadas em Inteligência Artificial (IA). Inspirado na Estratégia Brasileira de IA (EBIA), na Política Brasileira de IA (PBIA), no Framework Ético do MGI (2025), e em referências internacionais (UNDP, Oxford Insights), o documento foi revisado para alinhar os critérios de maturidade à realidade operacional, orçamentária e institucional do setor público.

A avaliação é estruturada em dimensões, cada uma com critérios realistas, níveis de maturidade ajustados e obrigatoriedade clara, facilitando diagnósticos factíveis e planos de ação escalonáveis.

2. Dimensões de Avaliação

2.1 Recursos Humanos

Critério	Descrição	Obrigatório?	Níveis de Maturidade (Realistas)
Capacitação Básica em Dados e IA	Existência de servidores com conhecimento mínimo em análise de dados, lógica de algoritmos e ética em IA.	Sim	• Inicial: Nenhum servidor com formação específica. • Intermediário: Pelo menos 1 servidor com curso introdutório (ex.: ENAP, Coursera, Serpro). • Avançado: Equipe multidisciplinar com capacitação contínua e parcerias com universidades.
Liderança com Visão Digital	Liderança (ex.: secretário, diretor) que entende riscos e oportunidades da IA.	Sim	• Inicial: Sem interesse ou priorização. • Intermediário: Apoio verbal a iniciativas digitais, sem alocação de recursos. • Avançado: Líder nomeado como “responsável por inovação em IA”, com orçamento e autonomia.
Diversidade nas Equipes Técnicas	Esforço para incluir diversidade (gênero, raça, região) nas equipes envolvidas com IA.	Recomendado	• Inicial: Sem atenção à diversidade. • Intermediário: Inclusão de pelo menos 1 pessoa de grupo sub-representado na equipe técnica. • Avançado: Metas explícitas e monitoramento contínuo, alinhadas à LGPD e PBIA.

Desenvolvimento de Talentos Locais	Parcerias com universidades locais para desenvolvimento de expertise nacional (princípio BRICS)	Recomendado	• Inicial: Sem parcerias formais • Intermediário: Acordos pontuais • Avançado: Programa estruturado de cooperação

2.2 Recursos Tecnológicos

Critério	Descrição	Obrigatório?	Níveis de Maturidade
Acesso a Ferramentas Básicas de IA	Disponibilidade de software livre ou licenciado para prototipagem (ex.: Python, scikit-learn, Hugging Face).	Sim	• Inicial: Uso esporádico, sem suporte técnico. • Intermediário: Acesso controlado via TI, com políticas de uso. • Avançado: Ambiente padronizado (ex.: JupyterHub interno) com suporte de TI.
Segurança Mínima em Modelos	Medidas básicas contra vieses, erros ou ataques (ex.: validação cruzada, documentação de decisões).	Sim	• Inicial: Sem validação. • Intermediário: Testes manuais em amostras pequenas. • Avançado: Pipeline automatizado com explicações (ex.: SHAP/LIME) e registro de decisões.
Infraestrutura de Processamento	Capacidade mínima para rodar modelos (mesmo que em nuvem pública ou parcerias).	Recomendado	• Inicial: Computadores comuns, sem GPU. • Intermediário: Acesso esporádico a nuvem (ex.: AWS Educacional, Azure Gov). • Avançado: Parceria com datacenter nacional ou cloud soberana (ex.: Cloud BR).

2.3 Infraestrutura

Critério	Descrição	Obrigatório?	Níveis de Maturidade
Conectividade Básica e Estável	Acesso à internet com largura de banda suficiente para transferência de dados.	Sim	• Inicial: Conexão instável ou compartilhada. • Intermediário: Banda dedicada para equipe técnica. • Avançado: Rede segura com SLA e backup.
Integração com Sistemas Públicos	Capacidade de conectar soluções de IA a sistemas existentes (ex.: SEI, e-SUS, SIGA).	Sim	• Inicial: Sistema isolado, sem integração. • Intermediário: Exportação manual de dados (CSV, Excel). • Avançado: APIs oficiais ou middleware compatível com GOV.BR.
Sustentabilidade	Consideração mínima	Recom	• Inicial: Sem preocupação.

Ambiental	ao impacto ambiental (ex.: evitar treinamento desnecessário de modelos grandes).	endado	• Intermediário: Preferência por modelos pré-treinados. • Avançado: Relatório anual de emissões estimadas de CO_2.

2.4 Dados

Critério	**Descrição**	**Obrigatório?**	**Níveis de Maturidade**
Qualidade Mínima dos Dados	Dados com identificação clara de fonte, formato e atualização.	Sim	• Inicial: Planilhas desorganizadas, sem metadados. • Intermediário: Base de dados com colunas nomeadas e datas de atualização. • Avançado: Catálogo de dados com qualidade mensurada (ex.: completude >90%).
Conformidade com LGPD	Tratamento adequado de dados pessoais, mesmo em fases de prototipagem.	Sim	• Inicial: Dados sensíveis usados sem anonimização. • Intermediário: Uso de pseudonimização ou dados sintéticos. • Avançado: DPIA (Avaliação de Impacto à Proteção de Dados) realizada antes do projeto.
Governança de Dados Básica	Existência de regras mínimas sobre quem acessa, altera ou usa os dados.	Recomendado	• Inicial: Qualquer um pode editar. • Intermediário: Controle de acesso por perfil. • Avançado: Versionamento (ex.: DVC) e catálogo federado (ex.: data.gov.br).

2.5 Governança e Accountability

Critério	Descrição	Obrigatório?	Níveis de Maturidade
Avaliação de Impacto Ético (EIA)	Realização de avaliação de impacto antes da implementação de sistemas de IA de alto risco (inspirado na UNESCO)	Sim	• Inicial: Sem avaliação formal • Intermediário: Avaliação ad-hoc para projetos maiores • Avançado: EIA estruturada obrigatória com consulta a stakeholders
Registro Público de Algoritmos	Manutenção de repositório transparente de sistemas de IA utilizados (prática da OCDE/GPAI)	Sim	• Inicial: Sem registro • Intermediário: Registro interno básico • Avançado: Registro público com documentação técnica e explicações
Mecanismo de Contestação	Canal para cidadãos contestarem decisões automatizadas	Sim	• Inicial: Sem canal específico • Intermediário: Ouvidoria genérica • Avançado: Canal dedicado com prazos definidos e revisão humana garantida

Comitê de Ética em IA	Estrutura multidisciplinar para supervisão ética	Recomendado	• Inicial: Sem comitê • Intermediário: Grupo informal • Avançado: Comitê formal com representação diversa

2.6 Transparência e Explicabilidade

Critério	Descrição	Obrigatório?	Níveis de Maturidade
Documentação Técnica	Registro de decisões de design, limitações e riscos conhecidos	Sim	• Inicial: Sem documentação • Intermediário: Documentação básica interna • Avançado: Documentação completa com metodologia de transparência
Explicabilidade das Decisões	Capacidade de explicar decisões automatizadas em linguagem simples	Sim (para decisões de alto impacto)	• Inicial: Sistema "caixa-preta" • Intermediário: Explicações técnicas disponíveis • Avançado: Interface para explicações acessíveis ao cidadão
Comunicação com Cidadãos	Informação clara quando IA é utilizada em serviços públicos	Sim	• Inicial: Sem comunicação • Intermediário: Aviso genérico • Avançado: Comunicação detalhada com direitos do cidadão

2.7 Open Source

Critério	Descrição	Obrigatório?	Níveis de Maturidade
Uso de Modelos Abertos	Preferência por soluções open source	Recomendado	• Inicial: Dependência de soluções proprietárias • Intermediário: Avaliação de alternativas abertas • Avançado: Priorização de open source com contribuições à comunidade

3. Princípios Gerais

- Pragmatismo: Reconhece que muitos órgãos estão no nível "Inicial" e propõe caminhos g
raduais.
- Custo-benefício: Prioriza soluções de baixo custo (ex.: IA generativa com modelos abertos).
- Colaboração: Incentiva redes de cooperação entre órgãos, universidades e Serpro/ENAP.
- Ética realista: Foca em mitigar riscos concretos (ex.: discriminação algorítmica) em vez de exigir perfeição.

- Alinhamento legal: Todos os critérios obrigatórios são compatíveis com LGPD, Lei de Acesso à Informação e PBIA.

4. Implementação Prática (Mais Acessível)

Passos Simplificados
1. Diagnóstico Rápido: Use a checklist abaixo (Sim/Parcial/Não) com foco nos critérios obrigatórios.
2. Priorização: Se >50% dos critérios obrigatórios forem "Não", foque em capacitação básica + governança mínima.
3. Piloto Leve: Comece com um caso de uso simples (ex.: classificação automática de e-mails ou pedidos de informação).
4. Monitoramento Contínuo: Reavalie a cada 6–12 meses, mesmo sem projeto ativo.

Checklist Fundamental

Marque Sim apenas se houver evidência concreta:
- [ ] Existe pelo menos 1 servidor com formação básica em dados ou IA?
- [ ] Há apoio da liderança (mesmo que informal) para experimentar IA?
- [ ] Os dados usados não contêm informações pessoais não tratadas?
- [ ] A solução não substitui decisão humana em casos de alto risco (ex.: concessão de benefícios)?
- [ ] Existe canal para contestação de decisões automatizadas?
- [ ] O projeto foi documentado (mesmo que em um documento simples)?

> Interpretação:
> - 5–6 “Sim”: Pronto para piloto.
> - 3–4 “Sim”: Precisa de ajustes mínimos.
> - <3 “Sim”: Invista em capacitação e governança antes de qualquer desenvolvimento.

Insights from the AI Readiness Check

What we learned from 5,000 public servants in 2025

The table below provides a snapshot view of the key insights gathered from users of the AI Readiness Check in 2025. The colour grading of the cells represent the percentage of respondents who responded positively to the five questions in each section.

SECTION	TOPIC	LEADERS (n=607)	IMPLEMENTERS (n=770)	USERS (n=3,435)
1	Workforce readiness	**Medium** The majority of leaders say they provide access to AI tools and training, but very few (around 30%) have thought about the impacts of augmentation and automation or people's jobs.	**High** High readiness driven by positive attitudes about AI's potential and high levels of experimentation (both above 90%). There are significant gaps with prompt engineering skills and developing critical mindsets toward AI.	**High** The vast majority of public servants (>90%) are optimistic about AI's potential and confident in their core ICT skills. Technical awareness of AI is much lower (45%), as are critical mindsets about augmentation versus automation.
2	Ability to apply AI in government	**Low** Responses indicate a lack of stakeholder engagement in developing AI projects, low levels of data readiness and the absence of evaluation.	**Medium** Most (63%) can take a problem-centred approach to implementing technology but there are gaps in knowledge about specific approaches and metrics for procuring and evaluating AI solutions.	**Medium** Around 75% say they use generative AI tools and carefully check outputs before implementing them. However, only 35% say they can apply prompting skills to shape the quality of these outputs.
3	Ability to apply AI ethically	**Medium** Core data protection policies provide a base layer of governance but there is a lack of transparency around the use of algorithmic systems or consideration of AI's environmental impact.	**Medium** Very few are aware of frameworks for ethical AI adoption (26% — drops to 15% among those actively working on AI projects). But there is stronger confidence around core principles and practices for data protection.	**Medium** Most are aware of basic ethical risks posed by using AI (particularly bias) and are familiar with core data protection policies. Far fewer can engage critically with the underlying data used to produce AI outputs.
4	Promoting AI innovation	**Medium** Nearly 70% say they are running pilots, but few (<45%) have the strategic foundation to prioritise potential opportunities, evaluate impact and scale up successful initiatives.	**High** A majority are actively involved with AI projects (58%) and many more are following AI developments in their field. However, few (34%) have a learning plan to address gaps in their AI competencies.	**Medium** Very few (27%) are actively involved with AI projects in their organisation, but around half say they are actively experimenting with genAI tools and sharing learnings with peers. There are gaps in understanding the core link between data and AI innovation.

Checklist de Pré-Produção para Solução de IA - Versão Abrangente

1. DEFINIÇÃO DO PROBLEMA & VIABILIDADE

- [ ] Objetivo de Negócio Claramente Definido
  - Problema a ser resolvido explicitado
  - Métricas de sucesso de negócio definidas (ex: ROI, redução de custos)
  - Critérios de aceitação com stakeholders

- [ ] Análise de Viabilidade Técnica
  - Complexidade do problema avaliada
  - Disponibilidade de dados verificada
  - Capacidade técnica da equipe confirmada
  - Solução de IA justificada vs. abordagem tradicional

- [ ] Análise de Viabilidade Ética e Legal
  - Impacto social avaliado
  - Conformidade regulatória verificada
  - Processo de aprovação ética definido

2. DADOS - QUALIDADE & PREPARAÇÃO

- [ ] Inventário e Compreensão de Dados
  - Fontes de dados identificadas e acessíveis
  - Esquema de dados documentado
  - Dicionário de dados criado
  - Volume mínimo de dados confirmado

- [ ] Garantia de Qualidade de Dados
  - Valores Ausentes: Taxa documentada (<10% crítico)
  - Duplicatas: Processo de identificação/remoção
  - Outliers: Estratégia de tratamento definida
  - Consistência: Validação de formatos e padrões
  - Integridade: Relacionamentos e chaves preservadas

- [ ] Pré-processamento e Engenharia de Features
  - Pipeline de transformação implementado
  - Features relevantes identificadas (correlação > 0.1)
  - Tratamento de dados categóricos/numericos
  - Normalização/padronização aplicada
  - Splits: Treino/Validação/Teste (70/15/15)

3. DESENVOLVIMENTO DO MODELO

- [ ] Seleção e Treinamento
  - Algoritmos baseline testados (pelo menos 3)
  - Hiperparâmetros otimizados (Grid/Random Search)
  - Validação cruzada implementada (k-fold ≥ 5)
  - Overfitting verificado (gap treino-teste < 15%)

- [ ] Avaliação do Modelo
  - Métricas técnicas calculadas:
    - Acurácia > 85% (problemas balanceados)
    - F1-score > 0.8 (problemas desbalanceados)
    - AUC-ROC > 0.75
  - Limiar de decisão otimizado
  - Matriz de confusão analisada
  - Curvas de aprendizado validadas

- [ ] Interpretabilidade e Explicabilidade
  - SHAP/LIME aplicado para modelos complexos
  - Features mais importantes identificadas
  - Exemplos de predições documentados

- Limitações do modelo documentadas

4. INFRAESTRUTRURA & DEPLOYMENT

- [ ] Arquitetura de Solução
  - Diagrama de arquitetura aprovado
  - On-premise vs. Cloud definido
  - Escalabilidade horizontal/vertical planejada
  - Latência máxima definida (< 200ms para tempo real)

- [ ] Pipeline de MLOps
  - Versionamento: Código (Git), Dados (DVC), Modelos (MLflow)
  - CI/CD para ML implementado
  - Pipeline de treinamento automatizado
  - Pipeline de inferência otimizado

- [ ] Requisitos de Sistema
  - Recursos computacionais provisionados:
    - CPU/RAM para treinamento
    - GPU (se necessário) disponível
    - Storage: Volume estimado × 3
  - Dependências containerizadas (Docker)
  - Orchestrator configurado (Kubernetes/AWS SageMaker)

5. TESTES & VALIDAÇÃO

- [ ] Testes Técnicos
  - Testes Unitários: Cobertura > 80%
  - Testes de Integração: Pipeline end-to-end
  - Testes de Carga: Até 200% da carga esperada
  - Testes de Segurança: OWASP ML aplicado
  - Testes de Recuperação: Failover testado

- [ ] Validação de Negócio
  - A/B testing planejado
  - MVP com usuários reais (piloto)
  - Feedback quantitativo e qualitativo coletado
  - KPI de negócio alcançado em ambiente controlado

6. GOVERNANÇA & CONFORMIDADE

- [ ] Privacidade e Segurança
  - PII identificada e anonimizada
  - Criptografia: dados em trânsito e repouso
  - Controle de acesso (RBAC) implementado
  - Logs de auditoria ativados
  - GDPR/LGPD compliance verificada

- [ ] Viés e Justiça
  - Análise de viés por subgrupos realizada
  - Métricas de fairness calculadas:
    - Disparate Impact: 0.8 < DI < 1.25
    - Equal Opportunity Difference < 0.1
  - Mitigação aplicada se necessário

7. MONITORAMENTO & OPERAÇÕES

- [ ] Plano de Monitoramento
  - Métricas definidas:
    - Desempenho do modelo (accuracy drift > 5%)
    - Data drift (PSI > 0.2)
    - Latência p95
    - Throughput
    - Taxa de erro
  - Dashboard configurado (Grafana/Datadog)
  - Alertas configurados (PagerDuty/Slack)

- [ ] Runbook Operacional
  - Procedimento de deploy documentado
  - Rollback plan definido (tempo < 30 min)
  - Escalonamento de problemas definido
  - Contatos de emergência listados

- [ ] Manutenção e Retreinamento
  - Gatilhos de retreinamento definidos:
    - Data drift detectado
    - Desempenho degradado
    - Periódico (ex: mensal)
  - Budget de retreinamento aprovado

8. DOCUMENTAÇÃO & TRANSFERÊNCIA

- [ ] Documentação Técnica
  - README do projeto completo
  - API documentation (OpenAPI/Swagger)
  - Model card preenchido
  - Diagramas de arquitetura atualizados

- [ ] Documentação Operacional
  - Runbooks para operações comuns
  - Guia de troubleshooting
  - FAQ de problemas conhecidos
  - Checklist de go-live

- [ ] Transferência de Conhecimento
  - Sessões de treinamento com equipe de operações
  - Pair programming com mantenedores futuros
  - Repositório de conhecimento centralizado
  - Lições aprendidas documentadas

9. GESTÃO DE PROJETO & RISCO

- [ ] Plano de Lançamento
  - Rollout gradual planejado (Canary → 5% → 25% → 100%)
  - Plano de comunicação com stakeholders
  - Data de go-live definida
  - Critérios de sucesso pós-lançamento

- [ ] Análise de Riscos
  - Riscos técnicos identificados e mitigados

  - Riscos operacionais endereçados
  - Plano de contingência para falhas críticas
  - Impacto financeiro de downtime calculado

- [ ] Recursos e Custos
  - Budget operacional aprovado
  - Equipe de sustentação designada
  - Custos de cloud/infraestrutura monitorados
  - ROI recalculado pós-piloto

CHECKLIST DE GATEWAY PARA PRODUÇÃO

Antes de prosseguir para produção, TODOS estes itens devem estar verificados:

✓ [ ] Performance do modelo atende critérios mínimos em dados não vistos
✓ [ ] Todos os testes automatizados passam
✓ [ ] Aprovação do comitê de ética obtida
✓ [ ] Conformidade legal verificada
✓ [ ] Plano de rollback testado e funcionando
✓ [ ] Equipe de operações treinada
✓ [ ] Monitoramento ativo configurado
✓ [ ] Documentação completa entregue
✓ [ ] Piloto bem-sucedido com usuários reais
✓ [ ] Aprovação formal do product owner

Versão do Checklist: 2.0
Última Atualização: [Data]
Próxima Revisão: [Data + 6 meses]
Aplicável a: Projetos de IA/ML de médio a grande porte

Notas:
- Adaptar critérios numéricos conforme o domínio
- Para projetos críticos, considerar checkpoints adicionais
- Manter evidências de cada item verificado

Este checklist deve ser usado como guia dinâmico - atualizar conforme lições aprendidas e mudanças no ambiente tecnológico e regulatório.